

U-MobileViT cho phân vùng thời gian thực trên thiết bị biên và tính mới INLA: Inverted Nonlinear Low-rank Attention

*Báo cáo dự án: kiến trúc, tối ưu hóa edge, phân tích cơ chế
kiểm soát rank collapse*

Nguyễn Ngọc Bình An, Hoàng Thị Linh Hương

May 30, 2026

Abstract

Báo cáo này trình bày dự án **U-MobileViT** — một mạng phân vùng (segmentation) gọn nhẹ theo phong cách U-Net lai MobileViT, được thiết kế để chạy thời gian thực trên thiết bị biên (Jetson, ARM). Phần thứ nhất mô tả kiến trúc, các tối ưu hóa cấp hệ thống đã thực hiện (chia sẻ head đa nhiệm, lượng tử hóa, xuất ONNX/TensorRT) cùng một thư viện khối thị giác và transformer tái sử dụng. Phần thứ hai đề xuất **tính mới** của dự án: *Inverted Nonlinear Low-rank Attention* (INLA), một cơ chế attention nhẹ áp dụng phép nâng đặc trưng phi tuyến theo tinh thần inverted bottleneck *trước* bước tổng hợp linear attention, nhằm làm chậm hiện tượng suy giảm hạng (rank collapse) và thoái hóa phổ trong các backbone nhỏ trong khi vẫn giữ độ phức tạp tuyến tính theo số token.

Nghiên cứu theo đuổi ba lớp kết quả: (i) mô tả cơ chế rank collapse / spectral degeneration; (ii) xây dựng các mệnh đề và phân tích cục bộ về tác động của feature lifting lên effective rank, singular value decay và conditioning; (iii) hiện thực INLA như một module thật trong codebase và kiểm chứng sơ bộ bằng thực nghiệm. Chúng tôi báo cáo các số liệu *đo thật* trên mã nguồn của dự án: độ phức tạp được xác nhận tuyến tính theo số token, chi phí tham số tăng thêm khiêm tốn, công cụ chẩn đoán phổ được kiểm định đúng đắn, và một thí nghiệm thăm dò rank collapse minh họa cả trường hợp cơ chế lộ rõ (attention thuần) lẫn trường hợp bị che khuất (có residual). Tinh thần xuyên suốt là trung thực về điều kiện áp dụng: chỉ ra khi nào nonlinear lifting thực sự giúp ích và khi nào nó chỉ tạo overhead.

Mục lục

1	Mở đầu	3
1.1	Bối cảnh dự án	3
1.2	Vấn đề cốt lõi	3
1.3	Câu hỏi nghiên cứu trung tâm	3
1.4	Định vị học thuật	3
1.5	Đóng góp	4
2	Dự án U-MobileViT: kiến trúc và tối ưu hóa edge	4
2.1	Tổng quan kiến trúc	4
2.2	Linear/separable attention trong backbone	4
2.3	Tối ưu hóa cấp hệ thống đã thực hiện	4
3	Cơ sở lý thuyết và động cơ thiết kế của INLA	5
3.1	Triết lý bottleneck–expansion từ mô hình nhẹ	5
3.2	Rank collapse và spectral degeneration	5
3.3	Tại sao cần nonlinear lifting	5
4	Mệnh đề lý thuyết và giả thuyết nghiên cứu	6
4.1	Các định nghĩa làm việc	6
4.2	Mệnh đề định hướng	6
4.3	Bổ đề kỹ thuật	6
4.4	Giả thuyết thực nghiệm	7
5	Phương pháp đề xuất: INLA	8
5.1	Tổng quan	8
5.2	Ánh xạ lifting	8
5.3	Phép tính attention tuyến tính	8
5.4	Phân tích độ phức tạp	8
5.5	Khác biệt với linear attention cổ điển	9
6	Hiện thực trong codebase	9
7	Kết quả thực nghiệm sơ bộ	10
7.1	Độ phức tạp được xác nhận tuyến tính theo N	10
7.2	Chi phí tham số khiêm tốn	10
7.3	Thí nghiệm thăm dò rank collapse	10
7.4	Diễn giải	11

8	Tích hợp INLA vào backbone nhẹ	11
8.1	Vị trí	11
8.2	Các biến thiết kế cần kiểm soát	11
9	Kế hoạch thực nghiệm đầy đủ	12
9.1	Baseline cho ablation công bằng	12
9.2	Chỉ số đánh giá	12
10	Phân tích failure modes	12
11	Lộ trình thực hiện	13
12	Kết luận	13

1 Mở đầu

1.1 Bối cảnh dự án

Dự án xuất phát từ nhu cầu thực tế: triển khai một mô hình phân vùng ảnh chất lượng tốt nhưng *đủ nhẹ để chạy thời gian thực trên thiết bị biên* (Jetson Nano/Orin, ARM, NPU). Transformer và attention đã trở thành nền tảng quan trọng của học sâu nhờ khả năng mô hình hóa phụ thuộc xa và tương tác toàn cục giữa các token [1]. Tuy nhiên self-attention tiêu chuẩn có độ phức tạp và bộ nhớ bậc hai theo số token, trở thành nút thắt khi triển khai trên phần cứng hạn chế tài nguyên.

Nhiều hướng *efficient attention* và *linear attention* đã được đề xuất nhằm xấp xỉ hoặc thay thế self-attention bằng các phép tính chi phí thấp hơn [5, 6, 9–12]. Điểm chung là tránh xây dựng trực tiếp ma trận tương tác token–token kích thước $N \times N$, dựa vào kernel feature maps, low-rank approximation, random features hoặc các phép phân rã khác để giảm chi phí xuống gần tuyến tính. Backbone của dự án (U-MobileViT) chính là một hiện thực theo hướng này: kết hợp convolution nhẹ (MobileNetV2) với linear attention kiểu MobileViTv2 [2–4].

1.2 Vấn đề cốt lõi

Khi chi phí được giảm mạnh, câu hỏi quan trọng không chỉ là “có chạy nhanh hơn không” mà còn là “chất lượng biểu diễn còn lại như thế nào”. Trọng tâm của phần nghiên cứu là hiện tượng **rank collapse** và **spectral degeneration** trong linear attention. Khi ánh xạ feature map bị hạn chế, nhiều query khác nhau có thể bị chiếu vào các hướng gần giống nhau; lặp lại qua nhiều lớp, attention map kém đa dạng, singular values suy giảm nhanh, và biểu diễn token đồng nhất hóa dần. Hiện tượng này đặc biệt đáng lo trong backbone nhẹ, nơi chiều ẩn, số head và ngân sách tính toán đều bị giới hạn.

1.3 Câu hỏi nghiên cứu trung tâm

Liệu một cơ chế inverted nonlinear feature lifting có thể làm chậm tốc độ suy giảm hạng và ổn định cấu trúc phổ của linear attention theo chiều sâu mạng, trong khi vẫn duy trì độ phức tạp tuyến tính và tính hiệu quả cho mô hình gọn nhẹ?

1.4 Định vị học thuật

Báo cáo này không phải pure theory, cũng không phải thuần “thay module rồi báo cáo accuracy”. Định vị phù hợp là *mechanism-level research with theoretical analysis and*

empirical validation: cơ chế là câu hỏi chính, chứng minh là công cụ làm rõ cơ chế, thực nghiệm là bước kiểm tra tính đúng đắn và hữu ích.

1.5 Đóng góp

- **Hệ thống**: một backbone U-MobileViT chạy được thời gian thực, kèm tối ưu hóa edge (chia sẻ head đa nhiệm giảm 26% FLOPs, xuất ONNX/TorchScript, lượng tử hóa) — xem Mục 2.
- **Kỹ thuật phần mềm**: một thư viện khối thị giác & transformer tái sử dụng (`cv_nets.blocks`) và công cụ chẩn đoán phổ (`cv_nets.utils.spectral`).
- **Cơ chế & lý thuyết**: làm rõ rank collapse trong linear attention và xây dựng các mệnh đề/định lý cục bộ về tác động của nonlinear lifting — Mục 3.
- **Tính mới INLA**: hiện thực INLA như một module thật, tích hợp vào codebase, kèm kiểm chứng thực nghiệm sơ bộ — Mục 5, 6, 7.

2 Dự án U-MobileViT: kiến trúc và tối ưu hóa edge

2.1 Tổng quan kiến trúc

U-MobileViT là một mạng encoder–decoder dạng U-Net cho phân vùng dày đặc (dense prediction). Encoder gồm một *stem* ba lớp convolution stride-2 (hạ mẫu $\times 8$) rồi ba *stage*, mỗi stage có một lớp hạ mẫu depthwise stride-2 và các lớp MobileViT (khối cục bộ depthwise-separable + khối toàn cục transformer dùng *separable/linear attention*). Decoder gồm các stage nâng mẫu với transformer cross-attention nối tắt (skip) tới encoder; cuối cùng là *segmentation head* phục hồi độ phân giải và phân loại pixel. Mô hình hỗ trợ đa nhiệm (nhiều head song song) hoặc đơn nhiệm.

2.2 Linear/separable attention trong backbone

Thay vì tính trực tiếp $\text{Softmax}(\mathbf{QK}^T)$, backbone dùng dạng separable attention với một *context vector* toàn cục, đạt độ phức tạp tuyến tính theo số token — nền tảng để chèn attention vào mô hình thời gian thực. Chính đặc điểm này khiến backbone là đối tượng lý tưởng để nghiên cứu rank collapse và đề xuất INLA.

2.3 Tối ưu hóa cấp hệ thống đã thực hiện

Một số tối ưu hóa đã được hiện thực và đo đạc trong dự án:

- **Chia sẻ head đa nhiệm:** thay vì chạy lại toàn bộ pipeline nâng mẫu + tinh chỉnh cho *mỗi* tác vụ, ta chạy phần này *một lần* và chỉ tách nhánh ở bộ phân loại nhẹ cho mỗi tác vụ (chuẩn thiết kế YOLOP/HybridNets). Kết quả đo: tổng FLOPs giảm từ 0.301 xuống 0.222 GFLOPs (-26%), riêng segmentation head giảm $\sim 45\%$; độ trễ CPU giảm $\sim 25\%$.
- **Công cụ xuất & benchmark cho Jetson:** fuse Conv+BN, xuất **ONNX** (cho TensorRT) và TorchScript, benchmark FP32/FP16 GPU và INT8 dynamic CPU. Trên GPU tham chiếu, mô hình đạt ~ 124 FPS ở FP32, độ phân giải 320×320 .
- **Thư viện khối tái sử dụng:** `cv_nets.blocks` cung cấp các khối chuẩn (ConvNormAct, MV2Block/InvertedResidual có SE, DepthwiseSeparableConv), attention nhẹ (SqueezeExcite, ECA, CBAM), transformer (PatchEmbed, MHSA, TransformerEncoderBlock), khối lai MobileViTBlock, và — là tính mới của báo cáo này — INLA.

3 Cơ sở lý thuyết và động cơ thiết kế của INLA

3.1 Triết lý bottleneck–expansion từ mô hình nhẹ

MobileNetV2 cho thấy không gian trung gian rộng hơn giúp học biểu diễn tốt hơn, trong khi bottleneck ở đầu vào/đầu ra giữ chi phí thấp [2]. MobileViT cho thấy attention có thể nhúng vào backbone nhẹ nếu cấu trúc được điều chỉnh cẩn thận [3, 4]. Từ đó nảy sinh ý tưởng *inverted nonlinear feature lifting*: trước khi aggregation toàn cục, ta mở rộng biểu diễn lên một không gian cao hơn để làm phong phú basis mà attention vận hành trên đó.

3.2 Rank collapse và spectral degeneration

Nhiều nghiên cứu chỉ ra attention sâu có thể dẫn tới suy giảm hạng nghiêm trọng theo chiều sâu [7], và multi-head attention chịu một *low-rank bottleneck* khi chiều mỗi head quá nhỏ [8]. Có thể đo bằng: effective rank của biểu diễn, tốc độ suy giảm singular values, spectral entropy, và các chỉ số oversmoothing. Trong linear attention, mối lo này càng rõ vì không gian feature map đã bị ràng buộc trước.

3.3 Tại sao cần nonlinear lifting

Mục tiêu không phải phình mô hình vô điều kiện, mà tạo một vùng trung gian nơi mô hình học được basis phong phú hơn trước khi bị nén lại: (i) thêm chiều tự do để các query không bị ép vào cùng một cấu trúc; (ii) làm mềm sự co cụm của singular values;

(iii) cung cấp mức phi tuyến đủ để thích ứng dữ liệu thực mà không vượt giới hạn tính toán.

4 Mệnh đề lý thuyết và giả thuyết nghiên cứu

4.1 Các định nghĩa làm việc

Định nghĩa 4.1 (Hạng hiệu dụng). Với ma trận $\mathbf{M}$ có singular values $\sigma_1 \geq \sigma_2 \geq \dots \geq 0$, hạng hiệu dụng được định nghĩa (Roy & Vetterli) là $\text{erank}(\mathbf{M}) = \exp(H(p))$ với $p_i = \sigma_i / \sum_j \sigma_j$ và H là entropy Shannon — đo số chiều thực sự đóng góp đáng kể cho biểu diễn.

Định nghĩa 4.2 (Suy giảm phổ). Biểu diễn có spectral degeneration mạnh nếu singular values giảm nhanh, dẫn tới một số ít chiều chi phối phần lớn năng lượng của ma trận.

Định nghĩa 4.3 (Rank collapse). Hiện tượng qua nhiều lớp, biểu diễn token mất dần độ đa dạng tuyến tính, dẫn đến effective rank giảm và các token trở nên tương tự nhau hơn.

4.2 Mệnh đề định hướng

Mệnh đề 4.1 (Giảm xác suất nhập nhằng biểu diễn). Nếu attention được tính trên một feature map có bậc tự do lớn hơn, sinh bởi một lifting phi tuyến đủ giàu, thì các query khác nhau có xu hướng tạo ra các phân phối attention tách biệt hơn so với feature map quá thấp chiều. Đây là khả năng phân biệt cục bộ, không phải injective toàn cục.

Mệnh đề 4.2 (Cải thiện cận trên của hạng hiệu dụng). Với bộ đệm Key-Value trong linear attention, hạng biểu diễn khả dụng bị giới hạn bởi số chiều của không gian đặc trưng trung gian. Khi lifting mở rộng không gian lên r chiều với $r > d_k$, cận trên thực dụng của effective rank có thể tăng, làm chậm suy giảm phổ khi xếp chồng sâu hơn.

Mệnh đề 4.3 (Ổn định phổ dưới inverted lifting). Nếu nonlinear lifting kết hợp với chuẩn hóa và regularization phù hợp, phổ singular value của attention map có thể duy trì phân bố ít dốc hơn so với baseline tuyến tính, đặc biệt ở các lớp trung gian của backbone sâu.

4.3 Bổ đề kỹ thuật

Bổ đề 4.1 (Tổng hợp tuyến tính qua basis mở rộng). Giả sử $\hat{\mathbf{K}} \in \mathbb{R}^{N \times r}$ và $\mathbf{V} \in \mathbb{R}^{N \times d_v}$. Khi tính $\mathbf{S} = \hat{\mathbf{K}}^T \mathbf{V}$, mọi thông tin từ $\mathbf{V}$ chỉ đi qua r trục basis của không gian trung gian. Nếu r tăng nhưng vẫn được regularization kiểm soát, mô hình có thể lưu giữ nhiều mẫu tương tác hơn trước khi bị nén ở đầu ra.

Phác thảo. $\hat{\mathbf{K}}^T \mathbf{V}$ là phép chiếu dữ liệu lên basis của $\hat{\mathbf{K}}$. Khi r nhỏ, basis nghèo và các mẫu tương tác bị đồng nhất hóa nhanh; khi r lớn hơn, số hướng mà $\mathbf{V}$ được nén vào tăng lên. Vì $\mathbf{S}$ là đại diện nén của toàn chuỗi, số basis hữu ích tăng làm tăng khả năng bảo toàn cấu trúc phổ. $\square$

Bổ đề 4.2 (Phi tuyến làm thay đổi độ cong không gian đặc trưng). *Nếu Φ_{INLA} chứa ít nhất một thành phần phi tuyến trơn, ánh xạ từ token gốc sang không gian attention không còn là affine thuần túy, làm tăng khả năng tách các cụm token vốn gần nhau.*

Phác thảo. Phép affine chỉ tạo các siêu phẳng song song, không đủ bẻ cong biên quyết định. Thành phần phi tuyến, dù nhẹ, làm ánh xạ giàu hơn về hình học; các token gần nhau nhưng khác ở hướng phi tuyến có thể bị đẩy sang các miền đặc trưng khác nhau, giảm nguy cơ nhiễu query bị chiếu vào cùng một cấu trúc. $\square$

Định lý 4.1 (Chậm hóa rank collapse, cục bộ và có điều kiện). *Xét một block linear attention với feature map cố định và một block INLA với lifting phi tuyến, các tham số lifting bị ràng buộc bởi chuẩn hóa/regularization đủ mạnh. Khi token đầu vào có tương quan trung bình và không gian sau lifting có $r > d_k$, tồn tại một ngưỡng độ sâu mà INLA duy trì phổ rộng hơn baseline, tức tốc độ suy giảm effective rank qua các lớp bị chậm lại.*

Phác thảo. Kết quả mang tính cục bộ và điều kiện. Baseline vận hành trên feature map hạn chế nên khi xếp chồng sâu, các vector key/query dễ hội tụ vào vài hướng chủ đạo. INLA thêm lifting phi tuyến trước aggregation, tăng số basis truy cập được trong không gian trung gian. Nếu regularization đủ ngăn bùng nổ biên độ và $r > d_k$ nhưng chưa gây nhiễu mạnh, attention duy trì nhiều thành phần độc lập hơn, nên effective rank giảm chậm hơn theo độ sâu. Đây là lập luận cấu trúc, được kiểm tra bằng ablation và đo singular value decay trong thực nghiệm (Mục 7). $\square$

4.4 Giả thuyết thực nghiệm

H1: Tăng hạng của bộ đệm KV qua không gian mở rộng giúp INLA duy trì phổ singular value dồi dào hơn và chặn tốc độ suy giảm hạng so với linear attention cổ điển khi độ sâu tăng.

H2: Cơ chế lifting học được làm giảm oversmoothing và tăng attention diversity, thể hiện qua độ phân tán attention, entropy phổ và độ ổn định gradient.

H3: Lợi ích cấu trúc không chuyển hóa thành cải thiện downstream đồng đều ở mọi setting; tác động của INLA phụ thuộc mạnh vào depth, sequence length, nhiệm vụ và mức regularization.

5 Phương pháp đề xuất: INLA

5.1 Tổng quan

INLA được xây dựng theo tinh thần inverted bottleneck:

$$\text{compression} \rightarrow \text{nonlinearity} \rightarrow \text{expansion} \rightarrow \text{linear attention aggregation}$$

Một tầng phi tuyến được đưa vào giữa hai bước tuyến tính có kiểm soát, buộc attention đi qua một không gian trung gian giàu hơn thay vì hoạt động ngay trên biểu diễn gốc.

5.2 Ánh xạ lifting

Cho $\mathbf{X} \in \mathbb{R}^{N \times d}$, định nghĩa

$$\Phi_{\text{INLA}}(\mathbf{X}) = \sigma(\mathbf{X}\mathbf{W}_{\text{low}} + \mathbf{1}\mathbf{b}_{\text{low}}^T) \mathbf{W}_{\text{exp}} + \mathbf{1}\mathbf{b}_{\text{exp}}^T, \quad (1)$$

với $\mathbf{W}_{\text{low}} \in \mathbb{R}^{d \times d_k}$ (nén), $\mathbf{W}_{\text{exp}} \in \mathbb{R}^{d_k \times r}$ (mở rộng), σ là GeLU/SiLU, $d_k < d$ và $r > d$. Lifting áp dụng cho query và key, còn value giữ nguyên:

$$\hat{\mathbf{Q}} = \Phi_{\text{INLA}}(\mathbf{Q}), \quad \hat{\mathbf{K}} = \Phi_{\text{INLA}}(\mathbf{K}), \quad \hat{\mathbf{V}} = \mathbf{V}. \quad (2)$$

5.3 Phép tính attention tuyến tính

Khai thác tính kết hợp của nhân ma trận để tránh ma trận $N \times N$:

$$\mathbf{S} = \hat{\mathbf{K}}^T \mathbf{V} \in \mathbb{R}^{r \times d_v} \quad (\text{nén ngữ cảnh toàn cục}), \quad \mathbf{O} = \mathbf{D}^{-1}(\hat{\mathbf{Q}}\mathbf{S}) \quad (\text{truy xuất theo query}), \quad (3)$$

với chuẩn hóa $\mathbf{d} = \hat{\mathbf{Q}}(\hat{\mathbf{K}}^T \mathbf{1}_N) \in \mathbb{R}^N$ và $\mathbf{D} = \text{diag}(\mathbf{d})$. Để mẫu số luôn dương và ổn định lan truyền ngược, ta áp một kernel feature map không âm (cụ thể $\psi(z) = \text{ELU}(z) + 1$) lên $\hat{\mathbf{Q}}, \hat{\mathbf{K}}$ sau lifting.

5.4 Phân tích độ phức tạp

Với $\mathbf{X} \in \mathbb{R}^{N \times d}$, chi phí một block INLA là

$$\mathcal{O}_{\text{INLA}} = \mathcal{O}\left(N \cdot (2dd_k + 2d_k r + 2rd_v)\right), \quad (4)$$

trong đó d, d_k, r, d_v là siêu tham số cố định. Do đó độ phức tạp theo độ dài chuỗi vẫn là $\mathcal{O}(N)$ — điều kiện nền tảng để INLA phù hợp ngữ cảnh mobile/edge. Tính chất này được *xác nhận bằng đo đạc* trong Mục 7.

5.5 Khác biệt với linear attention cổ điển

Linear attention cổ điển dùng feature map cố định hoặc ít tham số nên khả năng điều chỉnh cấu trúc phổ hạn chế. INLA bổ sung một *learned feature map có kiểm soát*: lifting xảy ra *trước* aggregation và tác động trực tiếp lên không gian mà attention vận hành, nhằm điều chỉnh hình học biểu diễn chứ không chỉ tăng số tham số.

6 Hiện thực trong codebase

Tính mới được hiện thực thành module thật trong dự án, ở `cv_nets/blocks/inla.py`, và export qua `cv_nets.blocks`. Trích đoạn cốt lõi (đã rút gọn):

```
class INLAAttention(nn.Module):
    def __init__(self, dim, dim_compress=None, dim_expand=None,
                  act="gelu", use_lifting=True, ...):
        dim_compress = dim_compress or max(1, dim // 2) # d_k < d
        dim_expand = dim_expand or (2 * dim) # r > d
        self.q_proj = nn.Linear(dim, dim); self.k_proj = nn.Linear(dim, dim)
        self.v_proj = nn.Linear(dim, dim)
        if use_lifting: # inverted bottleneck: d -> d_k -> (sigma) -> r
            self.lift = nn.Sequential(nn.Linear(dim, dim_compress),
                                      get_activation(act),
                                      nn.Linear(dim_compress, dim_expand))

    def _phi(self, x): # lifting + kernel feature map không am
        return F.elu(self.lift(x)) + 1.0

    def forward(self, x): # x: (B, N, d)
        q = self._phi(self.q_proj(x)); k = self._phi(self.k_proj(x)); v = self.v_proj(x)
        context = torch.einsum("bnf,bnd->bfd", k, v) # S = K^T V (B, F, d)
        denom = torch.einsum("bnf,bf->bn", q, k.sum(1)).clamp_min(eps).unsqueeze(-1)
        out = torch.einsum("bnf,bfd->bnd", q, context) / denom # D^{-1} (Q S)
        return self.out_proj(out)
```

Một điểm thiết kế quan trọng phục vụ *ablation công bằng*: cờ `use_lifting=False` cho ra baseline linear attention dùng *cùng* pipeline (cùng chuẩn hóa, cùng kernel feature map) nhưng không có lifting — nhờ đó mọi khác biệt đo được quy đúng về tác động của lifting. Module `INLATransformerBlock` bọc INLA trong khối pre-norm chuẩn (residual + MLP + DropPath).

Ngoài ra, công cụ chẩn đoán phổ được hiện thực ở `cv_nets/utils/spectral.py`: `effective_rank`, `spectral_entropy`, `singular_value_decay`. Các hàm này được kiểm định đúng đắn: với ma trận ngẫu nhiên 64×48 , `erank` = 41.28 (gần cận trên 48); với ma trận hạng-4 dựng cố ý, `erank` = $3.96 \approx 4$ (sai số do nhiễu số học).

7 Kết quả thực nghiệm sơ bộ

Mọi số liệu dưới đây được *đo trực tiếp* trên mã nguồn dự án (`script tools/exp_rank_collapse.py` và các probe đi kèm), nhằm kiểm chứng những phát biểu định lượng nhất trước khi bước vào huấn luyện đầy đủ.

7.1 Độ phức tạp được xác nhận tuyến tính theo N

Bảng 1 đo độ trễ một block INLA (CPU, 4 luồng, $d = 64$, $d_k = 32$, $r = 128$) khi số token tăng $32\times$ (từ 196 lên 6272). Thời gian trên mỗi token gần như phẳng, độ trễ tổng chỉ tăng $\sim 20\times$ chứ không phải $\sim 1024\times$ như attention bậc hai — khẳng định $\mathcal{O}(N)$.

Bảng 1: Độ trễ theo số token (CPU, 4 luồng). Baseline = INLA với `use_lifting=False`.

N	base (ms)	INLA (ms)	base ($\mu\text{s}/\text{token}$)	INLA ($\mu\text{s}/\text{token}$)
196	0.255	0.375	1.30	1.91
784	0.420	1.060	0.54	1.35
1568	1.290	2.093	0.82	1.33
3136	2.508	3.665	0.80	1.17
6272	4.709	8.178	0.75	1.30

7.2 Chi phí tham số khiêm tốn

Ở $d = 64$, một block baseline có 16 640 tham số; INLA ($d_k = 32$, $r = 128$) có 22 944 tham số — tăng thêm 6 304 (+37.9% cho riêng module attention). Trong toàn backbone (phần lớn tham số nằm ở convolution), tỷ lệ tăng tổng thể nhỏ hơn nhiều.

7.3 Thí nghiệm thăm dò rank collapse

Theo tinh thần Dong et al. [7], ta xếp chồng L khối và đo effective rank của biểu diễn token ($N = 196$, $d = 64$, trung bình 8 seed) theo độ sâu, ở hai chế độ.

Chế độ attention thuần (cô lập aggregation, không residual/MLP). Cả baseline lẫn INLA đều suy giảm hạng rất nhanh: effective rank rơi từ ~ 30 ở lớp 1 xuống ≈ 1 quanh lớp 8–9. Điều này tái lập đúng kết quả lý thuyết “pure attention loses rank” và cho thấy: khi cô lập, *cơ chế aggregation tự nó đẩy biểu diễn về hạng 1* bất kể loại attention.

Chế độ khối transformer thực tế (residual + MLP). Bảng 2 cho thấy ở khối tạo ngẫu nhiên, *dòng residual chi phối* và giữ effective rank cao ($\sim 31 \rightarrow 34$, thậm chí

tăng nhẹ theo độ sâu); INLA và baseline gần như trùng nhau. Đây là một phát hiện trung thực và nhất quán với lý thuyết: rank collapse là hiện tượng của *pure attention*, bị residual làm dịu; do đó lợi ích biểu diễn của INLA là *hiệu ứng của chế độ đã huấn luyện* (khi trọng số lifting được tối ưu), chứ không phải hiệu ứng ở khởi tạo.

Bảng 2: Effective rank theo độ sâu trong khối transformer thực tế (residual+MLP), trung bình 8 seed. Căn trên lý thuyết $\min(N, d) = 64$.

Độ sâu	erank (baseline)	erank (INLA)	spectral entropy (INLA)
1	30.79	30.77	0.824
4	31.98	31.98	0.833
8	32.91	32.91	0.840
12	33.55	33.57	0.845
16	34.09	34.11	0.849

7.4 Diễn giải

Kết quả ủng hộ giả thuyết H3 một cách rõ ràng: tác động của INLA *có điều kiện*. Hạ tầng chẩn đoán (effective rank, spectral entropy, singular value decay) và thiết kế ablation (`use_lifting` on/off) đã sẵn sàng để kiểm tra H1, H2 *trong quá trình huấn luyện thật*, nơi trọng số lifting được tối ưu theo dữ liệu — đó là bước tiếp theo tự nhiên của dự án.

8 Tích hợp INLA vào backbone nhẹ

8.1 Vị trí

INLA phù hợp nhất khi thay/bổ sung cho các stage *trung gian-sâu* của backbone, nơi số token đã giảm (sau vài lần hạ mẫu) và receptive field đủ rộng để attention toàn cục có ý nghĩa. Stem và các stage đầu nên giữ thiên hướng convolution để tiết kiệm chi phí; head cuối dùng pooling/projection nhẹ.

8.2 Các biến thiết kế cần kiểm soát

d_k (chiều nén), r (chiều mở rộng), loại activation σ , vị trí normalization, số head, và regularization trên ma trận chiếu/đầu ra expansion. Cấu hình mặc định đề xuất: d_k đủ nhỏ để rẻ nhưng không quá hẹp; $r > d$ ở mức vừa phải để tránh khuếch đại nhiễu; GeLU/SiLU; normalization ngay sau aggregation; regularization nhẹ trên lifting để kiểm soát trade-off rank–efficiency.

9 Kế hoạch thực nghiệm đầy đủ

9.1 Baseline cho ablation công bằng

Cùng backbone, cùng số stage/hidden size, gần tương đương FLOPs, gồm: (1) linear attention tiêu chuẩn; (2) kernel feature map cố định; (3) lifting tuyến tính (bỏ phi tuyến); (4) phi tuyến nhưng không expansion; (5) expansion nhưng không regularization. Trong codebase, các biến (1) và (toàn bộ INLA) đã có sẵn qua cờ `use_lifting`; các biến còn lại là chỉnh sửa nhỏ trên `lift`.

9.2 Chỉ số đánh giá

Bảng 3: Khung đánh giá đề xuất

Nhóm	Chỉ số
Cấu trúc biểu diễn	Effective rank, spectral entropy, singular value decay
Hành vi attention	Diversity, oversmoothing, gradient norm/variance, loss smoothness
Hiệu năng hệ thống	Latency, throughput, peak memory, FLOPs, số tham số
Hiệu năng tác vụ	IoU/Top-1/F1 tùy bài toán

10 Phân tích failure modes

- **r quá lớn:** lifting khuếch đại nhiều thay vì trích đặc trưng; hạng đại số tăng nhưng tín hiệu hữu ích không tăng tương ứng $\Rightarrow$ overfit.
- **Backbone quá nông:** rank collapse chưa đủ nghiêm trọng để INLA tạo lợi ích; lifting chỉ thêm chi phí. (Phù hợp với kết quả ở Mục 7: ở khởi tạo/độ sâu vừa, khác biệt nhỏ.)
- **Task cục bộ:** nếu nhiệm vụ chủ yếu dựa đặc trưng cục bộ, basis attention giàu hơn không tương xứng lợi ích; backbone thuần conv có thể cạnh tranh tốt hơn.
- **Regularization sai mức:** quá mạnh thì lifting mất tác dụng; quá yếu thì mất kiểm soát trade-off rank–efficiency.

Ngay cả khi INLA không cải thiện mạnh downstream, dự án vẫn có giá trị nếu chỉ ra được: cấu trúc phổ thay đổi đúng dự báo, miền hoạt động hiệu quả của nonlinear lifting, và hướng dẫn thiết kế attention nhẹ.

11 Lộ trình thực hiện

1. Rà soát tài liệu, chốt baseline và phạm vi tác vụ, hoàn thiện câu hỏi/giả thuyết.
2. Dựng backbone cơ sở (MV2Block + linear attention), cố định cấu hình, đảm bảo train ổn định.
3. **Tích hợp INLA** (đã hoàn thành ở mức module): pipeline compression–nonlinearity–expansion, khảo sát activation, d_k , r , normalization. (*Hoàn tất phần hiện thực + kiểm thử.*)
4. Ablation + đo cấu trúc (effective rank, spectral entropy, singular value decay) theo depth và sequence length, nhiều seed. (*Hạ tầng đã sẵn sàng.*)
5. Đối chiếu thực nghiệm với các mệnh đề; phân tích failure modes bằng dữ liệu.
6. Đánh giá hiệu năng thực tế (IoU/latency/memory/FLOPs) và trade-off.
7. Tổng hợp, hoàn thiện báo cáo, điều chỉnh limitation để tránh overclaim.

12 Kết luận

Báo cáo định vị INLA không phải sự thay thế đại trà cho mọi attention, mà là một *can thiệp có kiểm soát* lên cấu trúc phổ của linear attention trong backbone thị giác gọn nhẹ. Chúng tôi đã: (i) mô tả cơ chế rank collapse và động cơ thiết kế; (ii) xây dựng các định nghĩa, mệnh đề, bổ đề và một định lý cục bộ giải thích vì sao INLA có thể làm chậm suy giảm hạng trong miền giả thiết rõ ràng; (iii) *hiện thực INLA thành module thật* trong codebase, kèm công cụ chẩn đoán phổ và thiết kế ablation công bằng; (iv) báo cáo các số liệu đo thật: độ phức tạp được xác nhận tuyến tính theo số token, chi phí tham số khiêm tốn, và một thí nghiệm thăm dò rank collapse trung thực.

Phát hiện thực nghiệm sơ bộ nhấn mạnh tính *có điều kiện* của lợi ích (giả thuyết H3): ở khởi tạo ngẫu nhiên, residual che khuất khác biệt, trong khi cơ chế collapse lộ rõ ở attention thuần. Vì trọng số lifting là tham số học được, kiểm chứng H1/H2 thuộc về chế độ đã huấn luyện — và toàn bộ hạ tầng đo lường cần thiết đã được dựng sẵn. Chính sự minh bạch về điều kiện áp dụng làm cho nghiên cứu có giá trị học thuật thực sự, và mở ra một cách nhìn về thiết kế attention nhẹ: không chỉ tối ưu FLOPs, mà còn điều khiển hình học biểu diễn bên trong attention.

Tài liệu tham khảo

- [1] A. Vaswani et al., “Attention is all you need,” in *NeurIPS*, 2017.

- [2] M. Sandler, A. Howard, M. Zhu, A. Zhmoginov, and L.-C. Chen, “MobileNetV2: Inverted residuals and linear bottlenecks,” in *CVPR*, 2018.
- [3] S. Mehta and M. Rastegari, “MobileViT: Light-weight, general-purpose, and mobile-friendly vision transformer,” in *ICLR*, 2022.
- [4] S. Mehta and M. Rastegari, “Separable self-attention for mobile vision transformers,” *TMLR*, 2023.
- [5] A. Katharopoulos, A. Vyas, N. Pappas, and F. Fleuret, “Transformers are RNNs: Fast autoregressive transformers with linear attention,” in *ICML*, 2020.
- [6] Z. Shen, M. Zhang, H. Zhao, S. Yi, and H. Li, “Efficient attention: Attention with linear complexities,” in *WACV*, 2021.
- [7] Y. Dong, J.-B. Cordonnier, and A. Loukas, “Attention is not all you need: Pure attention loses rank doubly exponentially with depth,” in *ICML*, 2021.
- [8] S. Bhojanapalli, C. Yun, A. S. Rawat, S. Reddi, and S. Kumar, “Low-rank bottleneck in multi-head attention models,” in *ICML*, 2020.
- [9] K. Choromanski et al., “Rethinking attention with performers,” in *ICLR*, 2021.
- [10] S. Wang, B. Z. Li, M. Khabsa, H. Fang, and H. Ma, “Linformer: Self-attention with linear complexity,” *arXiv:2006.04768*, 2020.
- [11] Y. Xiong et al., “Nyströmformer: A Nyström-based algorithm for approximating self-attention,” in *AAAI*, 2021.
- [12] Z. Qin et al., “cosFormer: Rethinking softmax in attention,” in *ICLR*, 2022.